

We Need More Butterflies

Beatriz Alexandra Azeitona Mourato^{1,2} and Thales Barbutto Romanelli
Lopes^{1,3}

¹ Departamento de Engenharia Informática

² 2022224891, beatriz.a.mourato@gmail.com

³ 2022169928, thalesbrl@outlook.com

Resumo O desbalanceamento extremo de classes (*Data Starvation*) é um dos maiores desafios no treino de Redes Neurais Convolucionais (CNNs) em tarefas de identificação biológica de alta granularidade. Este projeto investiga a eficácia de modelos generativos na síntese de imagens para equilibrar um *dataset* composto por 75 espécies de borboletas e 5199 imagens macro-fotográficas. Propomos uma *pipeline* estado-da-arte (SOTA) comparando três paradigmas generativos condicionados: um Autoencoder Variacional Condicional (cVAE) com perda percetual, uma Rede Adversária Generativa Condicional (cDCGAN), e um Modelo Probabilístico de Difusão Condicional (DDPM). Através da otimização de hiperparâmetros via *Optuna*, o DDPM demonstrou maior superioridade na mitigação de *Mode Collapse*, atingindo um FID de 177.45. Para assegurar o rigor estatístico e mitigar o ruído generativo, introduzimos um algoritmo de *Hard Sample Mining* guiado por um Oráculo CNN operando sob um regime em cascata, bem como uma validação *Multi-Seed* ($N = 3$). Através da submissão em ambiente cego (Kaggle), analisamos os fenómenos de *Shortcut Learning* nas GANs e o efeito de regularização nas VAEs.

Keywords: Deep Learning · cVAE · cDCGAN · DDPM · Hard Sample Mining · Multi-Seed

1 Introdução

O sucesso da classificação de imagens com redes neuronais profundas baseia-se na premissa da disponibilidade massiva de dados perfeitamente distribuídos. Contudo, em domínios biológicos reais, a recolha de espécimes resulta frequentemente numa distribuição de cauda longa (*Long-tail distribution*). Este trabalho foca-se em mitigar esta falha num *dataset* contendo 75 classes de borboletas, utilizando abordagens de *Data Augmentation* generativo avançado.

O objetivo central passa por elevar artificialmente as classes mais raras ao patamar da classe maioritária, aumentando a fidelidade e diversidade estrutural

das amostras geradas através da otimização de modelos estado-da-arte (SOTA). Conforme os requisitos do projeto, a configuração da CNN *baseline* (arquitetura, otimizador e função de custo) não foi alterada. O trabalho focou-se exclusivamente na expansão do conjunto de treino através de imagens geradas artificialmente.

2 Descrição do Problema e Instabilidade Topológica

A base de dados é composta por 75 classes distintas de Lepidópteros, totalizando 5199 imagens. Para garantir a fiabilidade estatística e impedir cenários de vazamento de dados (*Data Leakage*), aplicou-se um particionamento estratificado rigoroso através do módulo *DataLoader*, segmentando o conjunto em 70% para Treino, 15% para Validação e 15% para Teste.

A Análise Exploratória de Dados (EDA) inicial revelou um desbalanceamento acentuado de cauda longa. Para identificar as classes minoritárias com maior necessidade de expansão, a CNN *baseline* foi treinada exclusivamente com o subconjunto real e avaliada no conjunto de teste. Desenvolveu-se um gráfico de dispersão mapeando o *Precision* vs *Recall* de cada classe, permitindo isolar os alvos críticos no quadrante inferior esquerdo (ver Figura 1). Através da execução *Multi-Seed*, comprovou-se a variação induzida pela inicialização estocástica dos pesos do classificador: a rede demonstrou fraquezas em classes distintas consoante a semente.

Por exemplo, na *Seed* 42 a rede apresentou pior desempenho nas espécies *Eastern Coma* e *Beckers White*. Já na *Seed* 100, os alvos críticos transferiram-se para a *Large Marble* e *Clouded Sulphur*. Na *Seed* 200, registou-se baixo desempenho na *Question Mark* e *Copper Tail*. O único padrão imutável inter-sementes foi a espécie *American Snoot*, caracterizando um cenário de escassez de dados biológicos absoluto e intrínseco ao padrão visual da classe.

Para cada semente, o sistema selecionou as 4 piores classes posicionadas no quadrante crítico ($\text{Precision} < 0.5$ e $\text{Recall} < 0.5$). O teto de balanceamento foi definido proporcionalmente via Pandas: gerar o volume exato de imagens sintéticas para que cada uma das 4 classes de cada semente atingisse o patamar da classe maioritária do *dataset* (TARGET_PER_CLASS).

3 Metodologia Generativa

3.1 Autoencoder Variacional Condicional (cVAE)

A primeira abordagem utilizou um cVAE condicional operando no domínio $[0, 1]$. O espaço latente foi condicionado através da injeção de camadas de *Embedding* da classe no Codificador e no Descodificador. Para combater o desfoque (*blurriness*) estrutural típico do erro quadrático (MSE), a função de custo foi expandida com uma Perda Percetual utilizando os mapas de características de uma rede *VGG (LPIPS)* pré-treinada. A função de perda total combinou MSE, LPIPS e

a Divergência de Kullback-Leibler ($\mathcal{D}_{KL}$):

$$\mathcal{L}_{VAE} = \mathcal{L}_{MSE} + \alpha \cdot \mathcal{L}_{LIPS} + \beta \cdot \mathcal{D}_{KL} \quad (1)$$

O parâmetro β atuou como força de regularização para impedir o colapso posterior. A curva de perda do treino pode ser consultada na Figura 2.

3.2 Rede Adversária Generativa Condicional (cDCGAN)

Para gerar texturas de alta frequência, implementou-se uma cDCGAN com 5 camadas convolucionais transpostas. O espaço de imagem foi normalizado para $[-1, 1]$ com ativação *Tanh* terminal no Gerador. Para estabilizar o jogo adversário de soma zero (*Min-Max Game*) e mitigar o *Mode Collapse* (evidenciado na dinâmica de convergência da Figura 3), implementou-se:

1. **TTUR (Two Time-Scale Update Rule):** Atualização assimétrica utilizando uma *Learning Rate* de 0.0001 para o Discriminador e de 0.0004 para o Gerador.
2. **Label Smoothing Unidirecional:** Suavização dos alvos reais do Discriminador para 0.8, evitando gradientes excessivamente punitivos.
3. **Regularização Espacial:** Introdução de camadas *Dropout2d*(0.3) nos blocos iniciais do Gerador para forçar a diversidade estatística.

3.3 Denoising Diffusion Probabilistic Models (DDPM)

O DDPM guiado por classes recorreu a uma arquitetura *PixelUNet* com normalização por grupos (*GroupNorm*) e blocos de atenção espacial na resolução mais baixa (4×4). O condicionamento foi executado fundindo o *Embedding* da espécie com o *Embedding* temporal sinusoide. O processo reverso de *Denoising* foi calibrado para $T = 1000$ passos. A rede foi otimizada via Erro Quadrático Médio (MSE), apresentando uma convergência estável (Figura 4).

3.4 Hard Sample Mining e Filtro de Sanidade em Cascata

A introdução cega de dados sintéticos num classificador introduz o risco de contaminação por ruído e anomalias geométricas intrínsecas ao espaço latente. Para mitigar este problema, desenvolveu-se uma abordagem de *Hard Sample Mining* operando como um filtro de qualidade pós-geração. Cada modelo gerou inicialmente um *pool* de 500 imagens candidatas por cada classe avaliada. A CNN *baseline* foi congelada e utilizada como avaliador estatístico. Para garantir a execução do fluxo e diagnosticar falhas, implementou-se um sistema em Cascata:

1. **Top-2 (Filtro Estrito):** Uma imagem candidata só é aceite se a classe biológica correta estiver nas previsões *Top-2* da CNN.
2. **Top-5 (Relaxamento):** Caso o modelo não atinja a quota exigida devido a fragilidades estruturais, o filtro expande a tolerância, aceitando imagens onde a classe correta surge no *Top-5*.

3. **Bypass Total:** Se o gerador entrar em *Mode Collapse* severo, o filtro é desativado para cumprir a quota de balanceamento e garantir a documentação empírica da falha.

As imagens aprovadas são ordenadas pela sua *Margem de Dúvida* ($Margem = P_{Top1} - P_{Top2}$). Selecionaram-se as amostras com menor margem, introduzindo no treino as imagens mais informativas para a definição das fronteiras de decisão da rede.

4 Experimental Setup: Otimização com Optuna

Todos os modelos operaram na resolução de 64×64 píxeis, com um *Batch Size* de 32 e treinos finais estendidos por 100 épocas. A otimização de hiperparâmetros foi automatizada via *Optuna*, recorrendo a ensaios de 10 épocas (*trials*) para reduzir o custo computacional, minimizando a Loss de Validação (cVAE), o *Kernel Inception Distance* (cDCGAN) e a *MSE Loss* terminal (DDPM).

A CNN *baseline* foi mantida inalterada, sendo composta por três blocos convolucionais duplos ('Conv2d', 'BatchNorm2d', 'ReLU', 'MaxPool2d'), um agrupamento adaptativo médio e um classificador linear denso com *Dropout* ($p = 0.5$). A avaliação final foi executada num regime de *Multi-Seed* ($N = 3$ execuções independentes nas sementes 42, 100 e 200), permitindo o cálculo do valor médio e desvio padrão.

5 Análise dos Resultados

5.1 Avaliação Quantitativa Generativa (FID e KID)

A proximidade entre as distribuições sintéticas e as amostras reais foi medida através das métricas FID e KID (Tabela 1). O modelo DDPM obteve os melhores resultados, registando o menor FID (177.45) e KID (0.1203), indicando maior capacidade de reproduzir texturas e padrões alares com exatidão. As amostras visuais de cada modelo encontram-se expostas na Figura 6.

Tabela 1: Métricas de avaliação generativa. Valores menores ($\downarrow$) indicam maior proximidade à distribuição real.

Modelo Generativo	FID $\downarrow$	KID $\downarrow$
cVAE (Baseline Generativa)	202.30	0.1700
cDCGAN	201.11	0.2171
DDPM	177.45	0.1203

5.2 Impacto na Classificação Global e Análise de Variância

Para avaliar o impacto prático no modelo discriminativo, a CNN foi re-treinada utilizando os dados reais combinados com as amostras sintéticas. A Tabela 2 consolida os resultados médios de avaliação no conjunto de teste.

Tabela 2: Desempenho global no conjunto de teste local ($Média \pm DesvioPadrão$, $N = 3$).

Configuração do Dataset	Accuracy (%) $\uparrow$	Macro F1 (%) $\uparrow$	Weighted F1 (%) $\uparrow$
Baseline (Apenas Imagens Reais)	71.97 ± 2.82	71.38 ± 2.76	71.55 ± 2.78
Baseline + cVAE Augmentation	72.56 ± 1.00	71.97 ± 0.78	72.28 ± 0.79
Baseline + cDCGAN Augmentation	71.80 ± 1.14	71.25 ± 1.34	71.48 ± 1.21
Baseline + DDPM Augmentation	73.67 ± 2.26	73.41 ± 2.43	73.58 ± 2.52

A avaliação inicial do *Baseline* expõe uma elevada variabilidade de desempenho dependente da semente ($\pm 2.78\%$ no Weighted F1). A injeção de dados via DDPM estabilizou a capacidade preditiva e registou a melhor média de generalização (73.58%). Constatou-se ainda que o cVAE atuou como um regularizador eficaz, comprimindo a variância para $\pm 0.79\%$, o que sugere que as amostras suavizadas atenuam o sobre-ajustamento.

5.3 Análise Granular de Desempenho e Trade-off

O impacto do aumento de dados foi analisado ao nível das classes minoritárias para investigar as limitações de cada modelo generativo. A variação de F1-Score foi mapeada na Figura 5, ilustrando o comportamento na **Seed 42**.

A injeção sintética induziu *Shortcut Learning* na abordagem adversária: a utilização de amostras cDCGAN reduziu o F1-Score da classe *American Snoot* de 0.38 para 0.00. A rede memorizou os artefactos artificiais do gerador, perdendo a capacidade de generalizar para as imagens reais de teste. Este padrão de redução observou-se novamente nas sementes 100 e 200 nas classes *Clouded Sulphur* e *Large Marble*.

Em contraste, a abordagem DDPM obteve os melhores resultados locais. Na Seed 42, o modelo de difusão aumentou o F1-Score da *Eastern Coma* de 0.00 para 0.57 e da *Beckers White* de 0.47 para 0.75. Esta capacidade de restauro traduziu-se num aumento de desempenho para todas as classes afetadas nas restantes sementes de teste.

Por último, avaliou-se o *Trade-off* global gerado pelo balanceamento artificial: verificar se o ganho de desempenho nas quatro classes alvo induziu penalizações nas restantes 71 espécies do *dataset*. O gráfico de barras divergentes (Figura 7) comprova que o aumento nas classes minoritárias com o modelo DDPM compensa, em larga escala, a ligeira degradação de precisão nas classes periféricas.

5.4 Inferência em Ambiente Cego (Kaggle)

A robustez dos modelos foi validada de forma cega via submissão das previsões a um servidor externo (Kaggle). As imagens de teste não participaram no processo de otimização dos parâmetros locais. Os resultados alcançados encontram-se na Tabela 3.

Tabela 3: F1-Score (%) no conjunto de teste cego (Kaggle).

Pipeline de Treino	Seed 42	Seed 100	Seed 200	Média $\pm$ Std
Baseline CNN	71.31	67.08	70.92	69.77 ± 2.34
CNN + cDCGAN	71.38	68.46	73.38	71.07 ± 2.48
CNN + DDPM	74.62	72.15	71.92	73.39 ± 1.75
CNN + cVAE	75.46	69.62	73.69	72.92 ± 3.00

A avaliação independente revela a vantagem de generalização do cVAE: a perda percentual imposta no treino gerou um efeito de regularização forte perante amostras totalmente novas. O cVAE obteve a pontuação isolada mais elevada no ambiente real com 75.46% (Seed 42). O classificador *Baseline* revelou baixo desempenho face a dados não vistos (67.08% na semente 100), consolidando a necessidade de *Data Augmentation* generativo em conjuntos de cauda longa.

6 Conclusão

Este estudo demonstrou que a expansão de *datasets* biológicos através de modelos generativos é uma estratégia viável para combater o desbalanceamento de classes, mas a sua eficácia é altamente dependente da fidelidade do modelo escolhido. Observámos que o aumento sintético via GANs em distribuições de cauda longa é instável, frequentemente conduzindo ao fenómeno de *Shortcut Learning*, onde a rede memoriza artefactos de alta frequência do gerador em vez de aprender características morfológicas reais.

O Modelo de Difusão (DDPM) estabeleceu o limite superior na fidelidade topológica, demonstrando que a modelação probabilística de ruído é superior na mitigação de *Mode Collapse* e na reconstrução métrica local. Contudo, o resultado mais surpreendente prendeu-se com o cVAE: a sua natureza inerentemente regularizadora, ao impor uma suavização percentual, atuou como um escudo algébrico contra o sobre-ajustamento, conferindo uma estabilidade preditiva superior em cenários de inferência cega (*Kaggle*), auxiliada pela robustez do filtro de *Hard Sample Mining* na seleção de amostras informativas.

Declaração de Utilização de Inteligência Artificial

Durante a elaboração deste relatório, recorreu-se a ferramentas de IA generativa para auxiliar a estruturação formal em L^AT_EX. Declara-se que todo o código

desenvolvido, a formulação da metodologia e os dados reportados resultam do trabalho integral dos autores.

7 Gráficos




Figura 1: Relação *Precision* vs *Recall* (Baseline, Seed 42).




Figura 2: Curva de Loss do cVAE (Erro de Reconstrução + Divergência KL).




Figura 3: Convergência do Discriminador e Gerador da cDCGAN.




Figura 4: Evolução do Erro Quadrático Médio (MSE) no treino do DDPM.




Figura 5: Variação de desempenho granular (Seed 42).




Figura 6: Amostras sintéticas dos três modelos: cVAE, cDCGAN e DDPM.




Figura 7: *Trade-off* induzido pelo DDPM.

Referências

1. Oliveira, W. D. G.: Data Augmentation via Generative Adversarial Networks aplicado em classificação de imagens. (2024).
2. Ho, J., Jain, A., Abbeel, P.: Denoising diffusion probabilistic models. Advances in neural information processing systems 33, 6840-6851 (2020).
3. Kingma, D. P., Welling, M.: Auto-encoding variational bayes. arXiv preprint arXiv:1312.6114 (2013).
4. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., Bengio, Y.: Generative adversarial nets. Advances in neural information processing systems 27 (2014).
5. Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., Hochreiter, S.: GANs trained by a two time-scale update rule converge to a local Nash equilibrium. NeurIPS 30 (2017).