

# The Butterfly Effect

Beatriz Alexandra Azeitona Mourato<sup>1,2</sup> and Thales Barbutto Romanelli  
Lopes<sup>1,3</sup>

<sup>1</sup> Departamento de Engenharia Informática

<sup>2</sup> 2022224891, [beatriz.a.mourato@gmail.com](mailto:beatriz.a.mourato@gmail.com)

<sup>3</sup> 2022169928, [thalesbrl@outlook.com](mailto:thalesbrl@outlook.com)

**Resumo** O crescente desenvolvimento da visão computacional tem impulsionado a criação de diversas arquiteturas de Machine Learning capazes de atingir resultados altamente satisfatórios. O presente artigo procura, através de uma abordagem empírica e científica, comparar modelos amplamente utilizados na literatura (MLP, CNN e ResNet) no contexto de um problema de classificação de imagens de borboletas. Foram exploradas diferentes arquiteturas, parâmetros e técnicas de aumento de dados (data augmentation), com o intuito de maximizar a capacidade de extração de padrões de cada modelo. Esta metodologia permitiu estabelecer um raciocínio comparativo sólido, o que evidencia o comportamento de cada modelo sob diferentes configurações e conduz à identificação da abordagem com melhor capacidade de generalização e desempenho global.

**Keywords:** Image Classification · Deep Learning · Convolutional Neural Networks · ResNet · Biodiversity Monitoring.

## 1 Introdução

Este projeto, desenvolvido para o Museu de Ciência da Universidade de Coimbra, tem como objetivo criar um sistema automatizado de visão computacional capaz de identificar espécies de borboletas a partir de fotografias.

Para alcançar este objetivo, o trabalho foca-se no desenvolvimento, treino e comparação de três arquiteturas de Redes Neurais Artificiais: *Multi-Layer Perceptrons* (MLP), Redes Convolucionais (CNN) e Redes Residuais (ResNet).

Ao longo do desenvolvimento, explora-se a otimização destes modelos através do ajuste de hiperparâmetros, testando diferentes funções de custo (como *Cross Entropy*, *MultiMarginLoss* e *Cross Entropy* com *LabelSmoothing*) e otimizadores (como ADAM, RMSprop, ADAMW e SGD). A avaliação e escolha do modelo ideal assentam numa seleção rigorosa de métricas, de modo a garantir que o sistema não apenas memoriza os dados de treino, mas adquire uma capacidade robusta de generalização para aplicações no mundo real.

## 2 Descrição do Problema

O problema abordado baseia-se na identificação dos padrões únicos e complexos das asas das borboletas. O grande desafio consiste em resolver um problema de classificação de imagens multi-classe, abrangendo 75 espécies distintas num conjunto de dados com mais de 5000 imagens, através dos três modelos explorados em contexto de aula (MLP, CNN e ResNet).

A seguir, será discutida cada etapa efetuada para a criação da *pipeline* de treino de cada modelo, desde o momento inicial de imersão e tratamento do *dataset*, até à implementação final dos modelos com as suas diferentes arquiteturas e parâmetros.

## 3 Approach

Com vista a uma maior eficiência no treino dos modelos, efetuou-se inicialmente uma análise exploratória da distribuição do *dataset*. Esta análise revelou um desequilíbrio evidente entre as classes de borboletas. Para mitigar este problema, garantir a robustez do sistema e reduzir o risco de *overfitting*, optou-se pela implementação conjunta de técnicas de *Oversampling* e *Data Augmentation*.

### 3.1 Data Augmentation

As técnicas de *Data Augmentation* aplicadas fundamentam-se em abordagens amplamente validadas na literatura para melhorar o desempenho de Redes Neurais Artificiais em problemas de classificação de imagens [1]. Foram aplicadas transformações espaciais e de cor durante o carregamento dos dados, nomeadamente: redimensionamento (*Resize*), espelhamento horizontal (*RandomHorizontalFlip*), rotações aleatórias (*RandomRotation*), variações de cor (*ColorJitter*) e oclusão aleatória (*RandomErasing*). Estas perturbações artificiais aumentam a complexidade e a variabilidade dos dados de treino, promovendo a capacidade de generalização das redes para novos dados empíricos.

### 3.2 Oversampling

Em conjunto com o aumento de dados, aplicou-se a técnica de amostragem ponderada através da função `WeightedRandomSampler` do PyTorch. Esta abordagem atribui diferentes probabilidades de seleção às amostras com base na frequência da sua classe original. Assim, garante-se que o modelo é exposto de forma mais equitativa a exemplos de classes minoritárias durante os *batches* de treino. A eficácia desta técnica foi alvo de avaliação ao longo das experiências, sendo possível quantificar o seu impacto na performance final dos modelos.

### 3.3 Formulação das Funções de Custo

A função de custo determina a superfície de erro sobre a qual o modelo converge. Para este problema multi-classe, avaliou-se o impacto de três formulações distintas:

- **Cross Entropy Loss:** Utilizada como função de referência, quantifica a divergência entre a previsão do modelo e a classe alvo, penalizando previsões incorretas de forma logarítmica.
- **Cross Entropy com Label Smoothing [2]:** Dada a elevada semelhança morfológica entre diversas espécies de borboletas, a rede está suscetível a um excesso de confiança nas suas previsões, resultando em *overfitting*. A introdução de um fator de *smoothing* (ex:  $\epsilon = 0.1$ ) penaliza as estimativas excessivamente confiantes, forçando a rede a distribuir as probabilidades de forma mais conservadora, o que melhora substancialmente a robustez da validação.
- **Multi Margin Loss:** Uma métrica alternativa que otimiza a margem de separação entre as classes previstas. O objetivo prático é forçar a arquitetura a aprender fronteiras de decisão (vetores de características) o mais distantes possível no espaço latente para as diferentes espécies.

### 3.4 Otimizadores e Dinâmicas de Convergência

A eficácia da descida do gradiente está diretamente dependente da escolha do algoritmo de otimização. Procedeu-se à avaliação comparativa dos seguintes métodos:

- **SGD (Stochastic Gradient Descent):** Implementado com fator de *momentum* (ex: 0.9). A acumulação de gradientes passados ajuda o modelo a escapar de mínimos locais na superfície de custo e a manter uma trajetória de convergência estável perante atualizações ruidosas.
- **ADAM e RMSprop:** Algoritmos baseados em taxas de aprendizagem adaptativas. Estes otimizadores ajustam o passo de atualização de forma independente para cada peso do modelo, com base na variância dos gradientes recentes. Demonstraram uma eficiência notável na propagação do erro ao longo das camadas mais profundas das arquiteturas ResNet.
- **ADAMW:** Uma variação do ADAM que corrige a formulação do decaimento de pesos (*Weight Decay*). A aplicação de uma taxa fixa de decaimento ( $1e^{-4}$ ) penaliza as magnitudes excessivas nos pesos da rede. Este mecanismo restringe a capacidade do modelo de memorizar características isoladas e ruidosas do conjunto de treino, forçando a extração de padrões globais e mitigando ativamente a sobre Adaptação (*overfitting*).

## 4 Experimental Setup

Para garantir a reprodutibilidade e permitir uma análise comparativa justa entre as diferentes arquiteturas (MLP, CNN e ResNet), o ambiente experimental

foi rigorosamente controlado através de um ficheiro de configurações centrais (`config.py`). Todo o desenvolvimento e treino foram suportados pela *framework* PyTorch.

O *dataset* foi devidamente particionado em conjuntos de treino e validação. A validação ocorreu em simultâneo com o treino para monitorizar a evolução da *accuracy* e guardar os pesos do melhor modelo (*best model checkpoint*).

O espaço de hiperparâmetros foi definido de forma metódica. Durante a fase empírica, o treino de todas as arquiteturas foi estabelecido para um máximo de 50 *epochs*, utilizando um *batch size* fixo de 32 imagens. As taxas de aprendizagem (*learning rates*) exploradas fixaram-se entre os valores de 0.01 e 0.001, variando consoante as dinâmicas do otimizador em teste. Relativamente às topologias adotadas, no caso específico da arquitetura MLP, definiu-se uma base de duas camadas ocultas (*hidden layers*) compostas por 1024 e 512 neurónios, respetivamente. Para a CNN construída de raiz, a arquitetura foi desenhada com três camadas convolucionais (com 32, 64 e 128 canais), intercaladas por operações de *Max Pooling*, seguidas de uma camada oculta totalmente conectada com 256 neurónios e regularização por *Dropout* (0.5). Por fim, adotou-se a arquitetura padrão ResNet-18, cuja única modificação estrutural consistiu na adaptação da camada linear final para acomodar o número de classes específico do conjunto de dados.

Relativamente à dimensionalidade dos dados de entrada, adotou-se inicialmente uma resolução de  $64 \times 64$  píxeis para todas as arquiteturas em estudo (MLP, CNN e ResNet). Esta decisão metodológica foi fundamental para estabelecer uma linha de base (*baseline*) justa e computacionalmente nivelada, permitindo a comparação direta do desempenho dos três modelos em estritas condições de igualdade. Contudo, numa fase posterior dedicada exclusivamente à otimização da ResNet, introduziu-se a técnica de *Transfer Learning*, inicializando a rede com pesos previamente otimizados em conjuntos de dados de grande escala (como o *ImageNet*) [3]. Para capitalizar esta transferência de conhecimento e explorar todo o potencial de extração hierárquica do modelo, as imagens de entrada foram redimensionadas para o formato padrão da arquitetura ( $224 \times 224$  píxeis). Esta convergência entre a expansão espacial e a utilização de pesos pré-treinados permitiu à rede processar texturas e pormenores morfológicos de grão muito mais fino, resultando num salto qualitativo substancial na capacidade de generalização e na robustez do modelo perante o conjunto de teste.

Por fim, o desempenho de cada configuração foi rigorosamente avaliado com recurso a métricas padronizadas para problemas de classificação multi-classe, nomeadamente: *Accuracy*, *Precision*, *Recall* e *F1-Score*, complementadas pela análise visual da distribuição de erros através de matrizes de confusão.

## 5 Análise dos resultados

Nesta secção, apresentamos os resultados obtidos após o treino e validação das três arquiteturas propostas. Por forma a avaliar o impacto das transformações espaciais e de cor no desempenho global, as experiências foram divididas em três

grandes cenários: com a aplicação de *Data Augmentation* (Tabela 1), sem a sua aplicação (Tabela 2) e um cenário final, onde buscamos otimizar os resultados da melhor arquitetura (Tabela 3). O valor apresentado em cada célula corresponde à métrica *weighted F1-Score* obtida.

**Tabela 1.** Resultados com Data Augmentation

|               | CrossEntropy |         |        |        | MultiMarginLoss |         |        |        | CrossEntropy LabelSmoothing |         |        |        |
|---------------|--------------|---------|--------|--------|-----------------|---------|--------|--------|-----------------------------|---------|--------|--------|
|               | ADAM         | RMSprop | ADAMW  | SGD    | ADAM            | RMSprop | ADAMW  | SGD    | ADAM                        | RMSprop | ADAMW  | SGD    |
| <b>MLP</b>    | 0.3512       | 0.3138  | 0.3648 | 0.3668 | 0.3117          | 0.2860  | 0.3001 | 0.3532 | 0.3625                      | 0.3182  | 0.3697 | 0.3799 |
| <b>CNN</b>    | 0.6586       | 0.7319  | 0.6884 | 0.7581 | 0.6112          | 0.6896  | 0.6487 | 0.5760 | 0.7062                      | 0.7466  | 0.7058 | 0.7444 |
| <b>ResNet</b> | 0.7338       | 0.7217  | 0.7297 | 0.7409 | 0.6995          | 0.7045  | 0.7041 | 0.6521 | <b>0.7632</b>               | 0.7612  | 0.7605 | 0.7627 |

**Tabela 2.** Resultados sem Data Augmentation

|               | CrossEntropy |         |        |        | MultiMarginLoss |         |        |        | CrossEntropy LabelSmoothing |         |        |        |
|---------------|--------------|---------|--------|--------|-----------------|---------|--------|--------|-----------------------------|---------|--------|--------|
|               | ADAM         | RMSprop | ADAMW  | SGD    | ADAM            | RMSprop | ADAMW  | SGD    | ADAM                        | RMSprop | ADAMW  | SGD    |
| <b>MLP</b>    | 0.3559       | 0.3471  | 0.3575 | 0.3450 | 0.3243          | 0.2856  | 0.3517 | 0.3574 | 0.3572                      | 0.3209  | 0.3538 | 0.4017 |
| <b>CNN</b>    | 0.6164       | 0.5790  | 0.5748 | 0.6106 | 0.5927          | 0.6084  | 0.5800 | 0.5139 | 0.6350                      | 0.6204  | 0.6077 | 0.6326 |
| <b>ResNet</b> | 0.6260       | 0.5965  | 0.6455 | 0.6120 | 0.6257          | 0.5785  | 0.6116 | 0.4571 | <b>0.6846</b>               | 0.6514  | 0.6744 | 0.6063 |

**Tabela 3.** Resultados - ResNet Otimizada (*Transfer Learning* e Image Size  $224 \times 224$ )

|               | CrossEntropy |         |        |        | MultiMarginLoss |         |        |        | CrossEntropy LabelSmoothing |         |        |               |
|---------------|--------------|---------|--------|--------|-----------------|---------|--------|--------|-----------------------------|---------|--------|---------------|
|               | ADAM         | RMSprop | ADAMW  | SGD    | ADAM            | RMSprop | ADAMW  | SGD    | ADAM                        | RMSprop | ADAMW  | SGD           |
| <b>ResNet</b> | 0.9112       | 0.8729  | 0.9063 | 0.9527 | 0.9179          | 0.8537  | 0.9125 | 0.9347 | 0.9345                      | 0.8985  | 0.9291 | <b>0.9627</b> |

Para complementar a avaliação quantitativa das tabelas, procedeu-se à inspeção visual do processo de otimização através das curvas de aprendizagem presentes no Anexo 7. A monitorização da evolução da *Accuracy* de treino e validação ao longo das 50 épocas (*epochs*) permite diagnosticar as dinâmicas de convergência e a capacidade de generalização das arquiteturas nas suas melhores configurações.

Observando o comportamento da arquitetura **MLP** (Figura 1), denota-se uma enorme discrepância entre o desempenho de treino e validação. Enquanto a métrica de treino sobe continuamente até níveis elevados ( $\sim 100\%$ ), a de validação estagna precocemente em valores muito baixos ( $\sim 35\text{-}40\%$ ). Esta lacuna maciça evidencia um cenário de extremo *overfitting* nos dados de treino, reforçando a tese de que o achatamento (*flattening*) da imagem destrói a coerência espacial necessária para a generalização, impedindo que a rede aprenda padrões visuais úteis para dados invisíveis.

Em contraste, a rede **CNN** (Figura 2) demonstra uma dinâmica de aprendizagem mais saudável. O gráfico ilustra um crescimento contínuo de ambas as métricas durante o treinamento. Nas épocas finais, denota-se uma lacuna perceptível de cerca de 7-10% entre treino ( $\sim 82\%$ ) e validação ( $\sim 75\%$ ), o que sugere um grau leve de *overfitting*. No entanto, a evolução paralela prova a eficácia das camadas convolucionais em extrair características mais robustas, e o uso de *Data Augmentation* parece ter impedido que o modelo memorizasse totalmente o conjunto de treino.

O expoente máximo da estabilidade e desempenho empírico é visível na evolução da **ResNet-18 otimizada** (Figura 3). Impulsionada pelo *Transfer Learning*, a rede alcança patamares de alta precisão muito rapidamente. Ambas as curvas convergem de forma estável para patamares elevados e próximos, com o treino atingindo 100% e a validação estabilizando acima de 95%. Isso confirma a robustez do modelo, a excelência da arquitetura residual na propagação do gradiente e a ausência de *overfitting* significativo, mesmo perante a complexidade das 75 classes estudadas.

## 5.1 Discussão

A análise comparativa dos resultados experimentais (Tabelas 1, 2 e 3) revela dinâmicas de aprendizagem radicalmente distintas entre as arquiteturas, destacando a importância do pré-processamento, da regularização e da preservação espacial em problemas de visão computacional. Destacam-se quatro fenômenos principais baseados nos dados observados:

*A Limitação Estrutural do MLP face a Transformações Espaciais:* A arquitetura *Multi-Layer Perceptron* apresentou os resultados mais baixos da experiência, oscilando genericamente entre os 28% e os 40%. Ao contrário dos modelos convolucionais, o *Data Augmentation* não trouxe benefícios ao MLP; pelo contrário, o modelo obteve o seu ligeiro pico de desempenho **sem** as transformações (40.17% com *CrossEntropy LabelSmoothing* e SGD, face a 37.99% com as mesmas configurações no cenário com aumento de dados). Este fenómeno justifica-se pela ausência de invariância espacial da arquitetura. Como o MLP processa a imagem achatando os píxeis num vetor unidimensional, transformações introduzidas pelo *Data Augmentation* alteram drasticamente a posição exata dos píxeis. O modelo tenta memorizar padrões posicionais em vez de extrair características visuais, sendo por isso incapaz de generalizar.

*O Salto de Generalização na CNN com Data Augmentation:* As redes convolucionais demonstraram uma excelente capacidade de extração de características espaciais, sendo as mais beneficiadas pelo *Data Augmentation*. Sem as perturbações artificiais, a CNN obteve um desempenho razoável, com o seu máximo a fixar-se nos 63.50% (*LabelSmoothing* com ADAM). No entanto, a introdução do *Data Augmentation* forçou os filtros da rede a aprenderem características morfológicas invariantes (independentemente de rotações ou escalas), atuando como um forte regularizador contra o *overfitting*. Isto traduziu-se num ganho superior

a 12 pontos percentuais, levando a CNN a atingir uns expressivos 75.81% de *F1-Score* (*CrossEntropy* com SGD).

*A Superioridade Inicial da ResNet:* A arquitetura ResNet confirmou a vantagem das redes profundas com ligações residuais para a extração hierárquica de características complexas. Mesmo operando na resolução base de  $64 \times 64$  píxeis, a ResNet já superava as restantes arquiteturas, atingindo **76.32%** (com *LabelSmoothing* e ADAM). Em tarefas de classificação visual complexa, onde fenómenos biológicos podem gerar sobreposição visual entre classes, o *Label Smoothing* revelou-se crucial por impedir que o modelo se tornasse excessivamente confiante em zonas de decisão ruidosas.

*Validação no Kaggle:* A verdadeira capacidade do modelo foi desbloqueada na fase de otimização (Tabela 3). A transição para a resolução de  $224 \times 224$  píxeis, combinada com a utilização de pesos pré-treinados (*Transfer Learning*), resultou num salto de desempenho significativo. A combinação destas técnicas com a função de custo *CrossEntropy LabelSmoothing* e o otimizador SGD elevou o *F1-Score* de validação para **96.27%**. A robustez e a capacidade de generalização desta configuração foram postas à prova de forma irrefutável na plataforma Kaggle, onde o modelo alcançou uma precisão de **94.61%** num conjunto de teste cego (*blind test set*). Esta ligeira e expectável discrepância ( $\sim 1.6\%$ ) entre a validação e o teste confirma que o modelo evitou o *overfitting*, consolidando uma representação visual altamente generalizável.

## 6 Conclusão

A presente experiência permitiu realizar uma análise exaustiva e comparativa entre três arquiteturas de redes neuronais (MLP, CNN e ResNet) aplicadas a um problema complexo de classificação visual. Os resultados evidenciaram que a topologia dos modelos dita de forma inegável a sua capacidade de generalização e abstração visual.

O modelo *Multi-Layer Perceptron* (MLP) revelou-se estruturalmente inadequado para lidar com dados de imagem, sofrendo com a quebra da invariância espacial e registando os piores desempenhos do estudo. Em contrapartida, a rede convolucional (CNN) desenhada de raiz demonstrou a eficácia da extração local de características, sublinhando em simultâneo o papel vital do *Data Augmentation* enquanto mecanismo de regularização indispensável para mitigar o *overfitting*.

O auge do desempenho empírico foi atingido com a arquitetura ResNet-18 otimizada. A convergência entre o *Transfer Learning* (através de pesos pré-treinados no *ImageNet*), o redimensionamento das imagens para  $224 \times 224$  píxeis, o aumento de dados e a aplicação da função de custo *CrossEntropy LabelSmoothing* (com o otimizador SGD) provou ser a configuração ideal. Esta abordagem culminou numa precisão máxima de **96.27%** em fase de validação e foi corroborada de forma contundente por um *F1-Score* de **94.61%** no conjunto de teste


independente da competição no Kaggle. Em suma, este estudo valida a superioridade incontestável de abordagens de *Deep Learning* suportadas por transferência de conhecimento para tarefas taxonómicas exigentes, resultando num sistema de classificação altamente fidedigno e robusto.

## Declaração de Utilização de Inteligência Artificial

Durante a elaboração deste relatório, recorreu-se a ferramentas de Inteligência Artificial generativa (modelos de linguagem de grande escala) com o propósito estrito de auxiliar no refinamento linguístico, correção gramatical e estruturação formal do texto em  $\text{\LaTeX}$ . Declara-se que todo o código desenvolvido, a recolha de dados, a análise empírica dos resultados obtidos e as conclusões científicas aqui apresentadas resultam inteiramente do trabalho e do pensamento crítico do(s) autor(es).


## 7 Anexo: Gráficos de Treino

Esta secção compila as curvas de aprendizagem referentes às melhores configurações de cada arquitetura analisada no estudo.




**Figura 1.** Curva de aprendizagem do melhor modelo MLP





**Figura 2.** Curva de aprendizagem do melhor modelo CNN



**Figura 3.** Curva de aprendizagem do modelo ResNet-18 Otimizada

## Referências

1. Shorten, C., Khoshgoftaar, T.M.: A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data* **6**, 60 (2019). <https://doi.org/10.1186/s40537-019-0197-0>
2. Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., Wojna, Z.: Rethinking the inception architecture for computer vision. *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2818–2826 (2016).
3. Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., Fei-Fei, L.: Imagenet: A large-scale hierarchical image database. *2009 IEEE conference on computer vision and pattern recognition*, 248–255 (2009).