

ArtBench Generative Modeling

Beatriz Alexandra Azeitona Mourato^{1,2} and Thales Barbuto Romanelli
Lopes^{1,3}

¹ Departamento de Engenharia Informática

² 2022224891, beatriz.a.mourato@gmail.com

³ 2022169928, thalesbrl@outlook.com

Resumo Este trabalho aborda a modelação generativa de imagens de obras de arte com recurso ao dataset ArtBench-10. O objetivo principal do estudo consiste em treinar, avaliar e comparar diferentes famílias de modelos generativos, nomeadamente Autoencoders Variacionais (VAE), Redes Generativas Adversariais (GAN) e Modelos de Difusão na síntese de novas imagens que respeitem a distribuição dos dados originais. O desempenho de cada arquitetura é quantificado rigorosamente através das métricas Fréchet Inception Distance (FID) e Kernel Inception Distance (KID), garantindo a reprodutibilidade através da execução em múltiplas *seeds* aleatórias.

Keywords: Generative AI · ArtBench-10 · Image Generation · VAE · GAN · Diffusion Models.

1 Introdução

O presente trabalho desenvolve-se no âmbito da unidade curricular de Inteligência Artificial Generativa e visa explorar a síntese de imagens no domínio artístico. Ao contrário das tarefas discriminativas, como a classificação de imagens, a modelação generativa exige que os modelos aprendam a distribuição subjacente aos dados de treino para produzir amostras originais e plausíveis. Este projeto requer a implementação de um *pipeline* completo, desde o pré-processamento de dados até à avaliação quantitativa rigorosa, comparando as vantagens e desvantagens de diferentes paradigmas arquiteturais de geração de imagem.

Para concretizar este objetivo, o estudo foca-se na modelação do dataset ArtBench-10, submetendo-o a três abordagens distintas que representam marcos fundamentais na literatura: Autoencoders Variacionais (VAE), Redes Generativas Adversariais (GAN) e Modelos de Difusão. O restante documento está estruturado da seguinte forma: a Secção 2 descreve o problema e o domínio dos dados. A Secção 3 detalha a metodologia e as opções arquiteturais. A Secção 4 documenta a configuração experimental, seguida da apresentação e discussão

empírica dos resultados na Secção 5. Por fim, a Secção 6 enumera as principais conclusões retiradas deste estudo.

2 Descrição do Problema

O domínio de aplicação deste projeto é o dataset ArtBench-10 [1], um conjunto de dados curado especificamente para avaliar modelos generativos em obras de arte. O dataset é composto por imagens com resolução de 32×32 píxeis em RGB, distribuídas por 10 estilos artísticos distintos e totalizando 50.000 amostras de treino.

A complexidade do problema reside na exigência de equilibrar a fidelidade visual, a diversidade das amostras e a consistência do estilo artístico gerado. O objetivo estrito não é encontrar uma "resposta certa" para cada imagem, mas garantir que o conjunto de imagens gerado se assemelha estatisticamente às obras de arte reais, um desafio que exige uma análise cuidadosa dos compromissos (*trade-offs*) inerentes a cada arquitetura.

3 Metodologia e Abordagem (*Approach*)

Para resolver este problema, são comparadas três famílias distintas de modelos generativos, sendo implementada pelo menos uma variação de cada:

- **Autoencoders (VAE)** [2]: Modelos reconhecidos por garantirem uma estabilidade elevada durante o treino e por apresentarem um espaço latente contínuo. Têm, no entanto, a desvantagem comum de gerar amostras com menor nitidez (mais desfocadas).
- **Generative Adversarial Networks (GAN)** [3]: Modelos que tipicamente produzem imagens mais nítidas e com tempos de geração rápidos, implementados aqui através de uma arquitetura baseada em DCGAN. A principal dificuldade desta abordagem prende-se com a instabilidade de treino.
- **Modelos de Difusão** [4]: Modelos estado da arte que oferecem alta qualidade e diversidade nas amostras, embora penalizem a eficiência computacional devido à lentidão do processo iterativo de inferência.

3.1 Arquitetura do Modelo

Autoencoder Variacional (VAE): A exploração desta família de modelos foi dividida em duas fases. A arquitetura inicial (Modelo Base) consistia num codificador (*encoder*) raso, com três camadas convolucionais (32, 64 e 128 canais) e ativações ReLU. Face aos resultados preliminares, foi desenvolvida uma arquitetura melhorada (Modelo Otimizado). A profundidade e a capacidade do modelo foram aumentadas (64, 128 e 256 canais no *bottleneck*). Para mitigar o desvanecimento do gradiente e o colapso do espaço latente, as ativações foram substituídas por *LeakyReLU* (declive de 0.2) e foi introduzida normalização espacial (*BatchNorm2d*) após cada convolução.

Generative Adversarial Network (GAN): Para a família das redes adversariais, implementou-se uma arquitetura DCGAN. O Gerador recebe um vetor latente de 128 dimensões e, através de uma sucessão de quatro camadas de convolução transposta com *BatchNorm* e ativações ReLU, reconstrói uma imagem RGB de 32×32 . A última camada utiliza a função *Tanh* para normalizar a saída no intervalo $[-1, 1]$. O Discriminador utiliza convoluções com *stride* e ativações *LeakyReLU* (0.2), culminando numa camada *Sigmoid* que fornece a probabilidade da amostra ser real. Os pesos foram inicializados com uma distribuição normal ($\mu = 0.0, \sigma = 0.02$).

Modelo de Difusão (DDPM): Adotou-se uma rede *PixelUNet* otimizada para o espaço de píxeis. A rede utiliza blocos residuais (*ResNetBlocks*) equipados com *GroupNorm* (32 grupos) e regularização *Dropout* (0.1). Para garantir coerência global nas imagens, foi introduzido um mecanismo de atenção (*Self-Attention*) no nível de resolução mais baixo (4×4 com 256 canais). A informação temporal (*timesteps*) é injetada via *embeddings* sinusoidais em cada bloco residual.

4 Experimental Setup

A metodologia experimental divide-se em duas fases principais. Inicialmente, o desenvolvimento, ajuste de hiperparâmetros e comparação preliminar das arquiteturas são realizados com recurso a um subconjunto restrito contendo apenas 20% dos dados de treino. Após a seleção das melhores configurações, procede-se ao treino final utilizando o dataset completo de 50.000 imagens.

A avaliação da qualidade e diversidade das imagens geradas assenta num protocolo estatístico rigoroso. Para cada configuração testada, são geradas 5.000 amostras, as quais são comparadas com 5.000 imagens reais do dataset. As métricas obrigatórias são:

- **Fréchet Inception Distance (FID):** Calculado globalmente utilizando as duas populações de 5.000 amostras (geradas vs. reais). Valores menores indicam maior proximidade com a distribuição original.
- **Kernel Inception Distance (KID):** Calculado extraíndo 50 subconjuntos aleatórios de tamanho 100 de ambas as distribuições. Reporta-se a média e o desvio padrão obtidos ao longo destes subconjuntos.

Para assegurar a robustez estatística e colmatar a natureza estocástica dos processos generativos, todo o protocolo de avaliação (cálculo de FID e KID) é repetido para 10 *seeds* aleatórias distintas para a configuração final, sendo reportada a média e o desvio padrão global dos resultados obtidos. As técnicas de pré-processamento e o código de avaliação foram mantidos fixos ao longo das várias experiências para garantir justiça na comparação.

4.1 Hiperparâmetros e Detalhes de Treino

Durante a fase de desenvolvimento, exploraram-se diversas configurações para identificar o ponto ótimo de operação de cada modelo. No caso do VAE, testaram-

se 8 combinações de hiperparâmetros, variando a dimensão latente (entre 16 e 128), o parâmetro β (1.0 e 0.7) e o otimizador (Adam e AdamW). Para a GAN, avaliaram-se 4 combinações, variando a dimensão latente (até 128) e o momento β_1 do otimizador Adam (0.5 e 0.9). Para estas duas famílias, a taxa de aprendizagem (*Learning Rate*) foi mantida fixa para isolar o efeito das restantes variáveis. Por fim, no Modelo de Difusão, testaram-se igualmente 8 combinações, analisando o impacto do número de canais base (32 e 64), do total de passos iterativos (*timesteps* de 500 e 1000) e de duas taxas de aprendizagem distintas (1×10^{-4} e 2×10^{-4}).

As configurações finais selecionadas foram:

- **VAE:** Dimensão latente de 128, $\beta = 0.7$, otimizador Adam com $LR = 1 \times 10^{-3}$.
- **GAN:** Dimensão latente de 128, $\beta_1 = 0.5$, otimizador Adam com $LR = 2 \times 10^{-4}$.
- **Difusão:** Canais base (model_channels) de 64, 1000 *timesteps*, otimizador Adam com $LR = 2 \times 10^{-4}$.

5 Análise dos Resultados

A metodologia experimental determinou uma fase inicial de testes utilizando apenas 20% do dataset de treino, com o objetivo de acelerar a iteração arquitetural, seguida de uma avaliação definitiva com o dataset completo (100%). As Tabelas 1 e 2 resumem o desempenho quantitativo, reportando a Média $\pm$ Desvio Padrão ao longo de 10 execuções independentes (*runs*) com *seeds* aleatórias.

Tabela 1: Resultados quantitativos obtidos com o subconjunto de desenvolvimento (20% dos dados de treino). Valores apresentados sobre a Média obtida.

Modelo Gerador	FID ($\downarrow$)	KID (Média) ($\downarrow$)
VAE (Modelo Base)	192.46	0.1807
VAE (Modelo Otimizado)	186.37	0.1767
DCGAN	78.37	0.0573
Modelo de Difusão	60.57	0.0377

Tabela 2: Avaliação Final: Resultados quantitativos globais obtidos após o treino com o dataset ArtBench-10 completo (50.000 imagens). Valores apresentados em Média $\pm$ Desvio Padrão (10 runs).

Modelo Gerador	FID ($\downarrow$)	KID (Média) ($\downarrow$)
VAE (Modelo Base)	181.18 $\pm$ 0.84	0.1739 $\pm$ 0.0011
VAE (Modelo Otimizado)	167.79 $\pm$ 0.38	0.1609 $\pm$ 0.0008
DCGAN	58.90 $\pm$ 0.59	0.0367 $\pm$ 0.0008
Modelo de Difusão	43.32 $\pm$ 0.38	0.0273 $\pm$ 0.0006

5.1 Discussão

A análise comparativa entre as três famílias de modelos (Tabelas 1 e 2) evidencia o impacto das diferentes arquiteturas na capacidade generativa. A evolução da qualidade visual entre a fase exploratória e a fase final pode ser consultada na Figura 1 e na Figura 2, respetivamente, documentando-se o comportamento das funções de perda associadas na Figura 3.

A versão primária do VAE, devido à sua fraca profundidade e ausência de mecanismos robustos de normalização, obteve um FID inicial de 181.18 no dataset completo. Ao introduzir o Modelo Otimizado, caracterizado pelo aumento dos canais convolucionais (até 256), implementação de *BatchNorm2d* e a utilização da LeakyReLU, registou-se uma melhoria significativa do FID para 167.79. Este ajuste mitigou parcialmente o colapso estrutural, embora o modelo permaneça penalizado pela tendência matemática da *loss* de reconstrução em gerar amostras mais desfocadas (visível na Figura 2). Ainda assim, a robustez contínua da topologia apreendida é demonstrada pelas transições suaves na interpolação do espaço latente (Figura 4).

A transição para modelos baseados em adversariedade e difusão resultou num salto qualitativo drástico. A DCGAN atingiu um FID de 58.90, confirmando a eficácia do seu discriminador em forçar a geração de texturas e contornos altamente nítidos (Figura 2). Destaca-se a importância da dimensão latente de 128 e do momento do otimizador ($\beta_1 = 0.5$), que foram cruciais para estabilizar o instável treino adversarial nesta resolução, sendo observado, também, que ainda poderia ser possível obter melhores resultados, por meio da obtenção do melhor modelo de acordo com a *loss* obtida, sendo esta, ao observarmos a (Figura 3), presente nos primeiros 10 epochs.

Contudo, o Modelo de Difusão estabeleceu o estado da arte nesta experiência, alcançando o melhor FID global de 43.32. Este desempenho superior justifica-se pela adoção da arquitetura *PixelUNet* otimizada com mecanismos de *Self-Attention* na resolução de 4×4 , o que dotou a rede de um contexto global indispensável para a coerência estrutural das pinturas. A utilização de 1000 passos de difusão e *GroupNorm* de 32 grupos permitiu um processo iterativo de *denoising* altamente preciso, gerando amostras que equilibram de forma notável a fidelidade visual e a diversidade exigidas pelo dataset ArtBench-10.

6 Conclusão

Este trabalho permitiu uma exploração exaustiva e empírica das três principais famílias de modelação generativa no contexto de imagens artísticas estruturadas. Conclui-se que o Modelo de Difusão apresenta a maior capacidade de capturar a distribuição de dados do ArtBench-10, proporcionando a melhor relação entre diversidade e qualidade (FID de 43.32), não obstante o seu elevado custo computacional na fase de inferência. A DCGAN afirmou-se como uma alternativa altamente competitiva e eficiente na amostragem (FID de 58.90), embora exija um rigoroso ajuste de hiperparâmetros para evitar instabilidades. Por fim, os Autoencoders Variacionais (VAE), apesar de garantirem a maior estabilidade de treino, evidenciaram limitações intrínsecas na geração de amostras com alta definição. Trabalhos futuros poderão focar-se na exploração de Modelos de Difusão Latente (LDMs) adaptados a resoluções mais baixas ou na destilação de modelos de difusão para acelerar o processo de amostragem.

Declaração de Utilização de Inteligência Artificial

Durante a elaboração deste relatório, recorreu-se a ferramentas de Inteligência Artificial generativa (modelos de linguagem de grande escala) com o propósito estrito de auxiliar no refinamento linguístico, correção gramatical e estruturação formal do texto em L^AT_EX. Declara-se que todo o código desenvolvido, a recolha de dados, a análise empírica dos resultados obtidos e as conclusões científicas aqui apresentadas resultam inteiramente do trabalho e do pensamento crítico do(s) autor(es).

7 Anexos: Gráficos e Resultados Visuais

Esta secção compila o registo visual das experiências, incluindo as grelhas de amostras geradas nas duas fases de treino (20% e 100%), o comportamento da função de perda (*loss*) ao longo das épocas e as viagens no espaço latente (interpolação).




Figura 1: Amostras geradas no final do treino exploratório com o subconjunto de 20%.







Figura 2: Amostras geradas após o treino final no dataset ArtBench-10 completo (50K imagens).




Loss: VAE Base



Loss: VAE Otimizado



Loss: DCGAN



Loss: Difusão

Figura 3: Curvas de aprendizagem (Loss) das configurações finais avaliadas a 100%.



Figura 4: Transição no espaço latente entre dois pontos aleatórios. Demonstra a continuidade do espaço apreendido pelas diferentes arquiteturas.

Referências

1. Liao, P., Li, X., Liu, X., Keutzer, K.: The artbench dataset: Benchmarking generative models with artworks. arXiv preprint arXiv:2206.11404 (2022).
2. Kingma, D.P., Welling, M.: Auto-encoding variational bayes. arXiv preprint arXiv:1312.6114 (2013).
3. Radford, A., Metz, L., Chintala, S.: Unsupervised representation learning with deep convolutional generative adversarial networks. arXiv preprint arXiv:1511.06434 (2015).
4. Ho, J., Jain, A., Abbeel, P.: Denoising diffusion probabilistic models. In Advances in Neural Information Processing Systems (NeurIPS) (2020).