

Tópicos de Ciência de Dados

2025/2026

Classificação de Atividades Humanas



FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D
COIMBRA

Beatriz Alexandra Azeitona Mourato N°2022224891

Thales Barbuto Romanelli Lopes N°2022169928

Índice

3.2. Análise da densidade de outliers no dataset transformado.....	2
3.4 Identificação de outliers através do Z-Score.....	3
3.5 Comparação de resultados.....	7
3.7 Detecção de Outliers via K-means e Comparação com Z-score.....	7
3.10 Modelagem linear para o módulo da aceleração e correção de outliers.....	9
3.11 Modelo linear com janela centrada no instante a prever.....	12
4.1 Análise da Significância Estatística e da Normalidade das Variáveis nas Diferentes Atividades.....	13
4.4 Importância das Variáveis e Redução Dimensional do Espaço de Features.....	14
4.4.1. Obtenção das Features Relativas à Compressão.....	17
4.4.2. Vantagens e Limitações da Abordagem.....	17
4.6 Identificação das melhores features segundo Fisher Score e ReliefF.....	18
4.6.1 Extração e Exemplificação das Features Seleccionadas para Compressão de Dados.....	22
4.6.2 Vantagens e limitações desta abordagem.....	23

3.2. Análise da densidade de outliers no dataset transformado

Foi realizada uma análise da densidade de outliers presentes no dataset transformado, considerando os módulos dos vetores de aceleração, giroscópio e magnetômetro para cada atividade e posição dos sensores. Após examinar os resultados obtidos é possível tirar informações importantes sobre cada vetor.

Ao analisar o vetor aceleração é possível observar uma densidade de outliers, com valores aproximados entre 0.22% a 25.67%, dependendo da atividade e do sensor. Além disso, é possível destacar as atividades 8, 9, 10 e 11 que apresentam as maiores densidades de outliers, o que pode ter relação com movimentos mais bruscos ou irregulares, típicos de ações de maior intensidade ou transição rápida.

Por outro lado, as atividades 2 e 3 apresentam as menores densidades de outliers, o que pode indicar movimentos mais estáveis e consistentes, provavelmente relacionados a ações de menor variação dinâmica.

Os sensores Left Lower Leg e Right Upper Leg tendem a apresentar densidades médias a elevadas, com densidades acima de 20% em algumas atividades. Já os restantes sensores mostram densidades mais moderadas entre 3% e 10% na maioria dos casos.

Já na análise do vetor giroscópio, observou-se uma distribuição mais estável de outliers, com valores aproximados entre 0.7% e 15.9%, dependendo da atividade e do sensor. Voltou a notar-se que as maiores concentrações de outliers surgiram nas atividades 8 a 11, especialmente nas regiões das pernas e dos pulsos, o que sugere movimentos rotacionais mais intensos nesses membros durante essas ações.

Por outro lado, as atividades 4, 5, 6 e 7 apresentaram baixos níveis de outliers, com valores inferiores a 2% em muitos sensores, indicando movimentos mais regulares e repetitivos.

Por fim, ao analisar o vetor magnetômetro, observamos que a densidade de outliers varia desde valores nulos 0% até cerca de 21%, dependendo da atividade e do sensor.

O sensor Chest destacou-se por registrar as maiores densidades médias de outliers, ultrapassando 20% em várias atividades (particularmente nas atividades 2, 3, 10 e 11).

Por outro lado, sensores nas pernas e pulsos mostraram, em geral, valores reduzidos, muitas vezes abaixo de 2%, evidenciando uma leitura magnética mais estável e menos suscetível a distorções.





Podemos então concluir que em termos gerais, o vetor aceleração mostrou ser o mais sensível a variações bruscas, refletindo fortemente a natureza dinâmica das atividades físicas. Já o vetor giroscópio apresentou menor dispersão global de outliers quando comparado ao vetor aceleração, o que pode estar relacionado à sua maior estabilidade na medição de rotações. E por fim, o vetor magnetômetro revelou-se o mais sensível a fatores externos e ambientais, apresentando comportamentos inconsistentes conforme a posição do sensor e a atividade executada.

3.4 Identificação de outliers através do Z-Score

Para este estudo, procedemos à detecção de outliers nos módulos dos vetores de aceleração, giroscópio e magnetômetro, utilizando o método do Z-score com diferentes limiares de corte: $k=3$, $k=3.5$ e $k=4$.

Realizamos uma análise tanto considerando a classificação das atividades quanto sem distinção de atividades, buscando reproduzir um cenário mais realista. Os gráficos apresentados abaixo foram selecionados entre diversos resultados obtidos, destacando os casos mais relevantes e ilustrativos das diferenças entre os valores de k , os vetores analisados e as posições dos sensores no corpo.

Optamos por apresentar os dados obtidos para o sensor Chest para os vetores aceleração e giroscópio e o sensor Left Wrist para o vetor magnetômetro, pois estes apresentaram uma densidade de outliers suficientemente representativa para evidenciar diferenças entre as atividades, facilitando a interpretação dos resultados nos gráficos. Todos os demais dados analisados estão disponíveis na pasta [data/zscore](#) do projeto.











Fig 1 - Gráficos do vetor aceleração do Chest com k=3, 3.5 e 4

Quando analisamos as atividades individualmente, é possível observar que certas transições rápidas, como atividade 8 – Stand → Sit, atividade 9 – Sit → Stand, atividade 10 – Stand → Sit and Talk e atividade 11 – Sit → Stand and Talk, geram uma maior densidade de outliers, chegando a 3,44%, refletindo o aumento da variabilidade do movimento nessas situações.

Por outro lado, ao considerar os dados sem distinção das atividades, simulando um cenário mais realista, a densidade global de outliers no sensor Chest foi de 2,21%, representando o comportamento médio do sensor ao longo de todo o período de captura.











Fig 2 - Gráficos do vetor giroscópio do Chest com k=3, 3.5 e 4

Quando analisamos as atividades individualmente, algumas transições rápidas, como atividade 8, 9, 10 e 11, assim como no vetor aceleração, apresentam maior densidade de outliers, chegando a 2,74%, refletindo a variabilidade dos movimentos rotacionais captados pelo giroscópio nessas situações.

Ao considerar os dados sem distinção das atividades, simulando um cenário mais realista, a densidade global de outliers no sensor Chest foi de 2,19%, refletindo o comportamento médio do sensor ao longo de todo o período de captura.






Fig 3 - Gráficos do vetor magnetômetro do Left Wrist com k=3, 3.5 e 4

Quando analisamos os dados do vetor de magnetômetro no sensor Left Wrist, é possível observar que certas atividades, especialmente as que envolvem movimentos mais intensos ou transições rápidas, como atividade 6 – Climb Stair, atividade 7 – Climb Stair and Talk e atividade 11 – Sit → Stand and Talk, apresentam uma maior densidade de outliers, chegando a 1,28%. Esses picos refletem a variabilidade dinâmica do movimento do punho durante essas ações.

Ao considerar os dados sem distinção das atividades, simulando um cenário mais realista, a densidade global de outliers no sensor Left Wrist foi de 0,32%, indicando que, de forma geral, o vetor de magnetômetro é bastante estável, mas ainda assim sensível a movimentos específicos.

Ao comparar os três vetores, observamos diferenças claras no comportamento dos outliers. O vetor de aceleração apresentou a maior sensibilidade, refletindo diretamente a intensidade e a variabilidade das atividades, com picos de outliers em transições rápidas como Stand → Sit (atividade 8) ou Sit → Stand and Talk (atividade 11). O giroscópio mostrou menor dispersão global de outliers, registrando variações mais moderadas e consistentes, especialmente no sensor Chest, evidenciando sua estabilidade na medição de rotações. Já o magnetômetro, representado pelo sensor Left Wrist, apresentou densidade de outliers globalmente baixa, indicando que o vetor magnetômetro é relativamente estável, mas ainda detecta variações pontuais em movimentos mais intensos ou transições bruscas.

Esta análise evidencia como cada vetor capta diferentes aspectos do movimento: a aceleração é sensível a mudanças rápidas de posição, o giroscópio mede rotações de forma mais estável e o magnetômetro registra variações menores, mas ainda relevantes em movimentos dinâmicos.

3.5 Comparação de resultados

Ao comparar os resultados de 3.1 e 3.4, observa-se que a aplicação do método Z-score reduziu drasticamente a densidade de outliers em todos os vetores e sensores. No caso do vetor de aceleração que apresentava inicialmente valores elevados de outliers, especialmente em transições rápidas (atividades 8 a 11), a detecção pelo Z-score diminuiu a quantidade de pontos extremos, filtrando movimentos abruptos que poderiam distorcer a análise. No caso do giroscópio, que já mostrava pouca variação, o método ajudou a suavizar os picos e distribuiu os outliers de forma mais uniforme, destacando apenas os movimentos mais intensos ou rotacionais. Já o vetor do magnetômetro, muito sensível a valores extremos isolados, apresentou uma redução ainda maior de outliers, mostrando que grande parte dos picos detectados inicialmente eram apenas ruídos esporádicos e não movimentos reais.

Esta comparação mostra que o Z-score é eficaz para normalizar a análise, removendo outliers extremos e permitindo uma interpretação mais clara das diferenças entre atividades e sensores, ao mesmo tempo em que preserva as variações relevantes de movimento detectadas por cada vetor.

3.7 Detecção de Outliers via K-means e Comparação com Z-score

Para a análise de outliers utilizando K-Means, selecionamos sensores que apresentaram uma densidade representativa de outliers e permitissem visualizar claramente as diferenças após a transformação. Para o vetor aceleração, escolhemos o Right Wrist, para o giroscópio, o Chest, e para o vetor magnetômetro, o Left Wrist. Os clusters foram definidos com $k=16$, correspondente ao número de labels no dataset. Esta abordagem permite comparar diretamente os resultados com os obtidos anteriormente pelo método do Z-score, evidenciando como o K-Means consegue agrupar melhor os dados e identificar desvios realmente relevantes. Os gráficos 3D apresentados a seguir ilustram visualmente a distribuição dos outliers para os vetores selecionados. Todos os demais resultados para outros sensores podem ser encontrados na pasta [data/kmean_outliers](#).




Fig 4 - K-mean e K-mean Outliers do vetor aceleração do Right Wrist com k=16

Comparando com os resultados do Z-score, onde 1,03% das amostras do Right Wrist foram identificadas como outliers, o K-Means mantém uma proporção semelhante, mas com uma distribuição mais uniforme e significativa dentro do contexto de cada cluster. Esta abordagem filtra picos isolados e facilita a análise dos movimentos atípicos, tornando a interpretação mais robusta.




Fig 5 - K-mean e K-mean Outliers do vetor giroscópico do Right Wrist com k=16

Comparando com os resultados obtidos pelo Z-score, nota-se que o método de K-means distribuiu os outliers de forma mais uniforme entre os clusters, destacando apenas os movimentos realmente atípicos ou rotacionais. A maioria dos picos extremos detectados

anteriormente pelo Z-score não se manteve nos clusters, evidenciando que grande parte dos outliers iniciais correspondia a variações pontuais e não a padrões de movimento significativos. Este comportamento facilita a interpretação de padrões globais de movimento e permite uma análise mais robusta da atividade física monitorada.




Fig 6 - K-mean e K-mean Outliers do vetor magnetômetro do Right Wrist com k=16

Para o vetor magnetômetro no Left Wrist, a aplicação do K-Means reduziu significativamente a densidade de outliers em comparação com o método do Z-score. Enquanto o Z-score evidenciava muitos picos isolados, principalmente em atividades com movimentos intensos ou abruptos, o K-Means permitiu agrupar os dados de forma mais estruturada, destacando apenas os valores que realmente se distanciam da maioria das amostras de cada cluster. Essa abordagem suaviza ruídos pontuais e facilita a visualização de padrões consistentes de outliers, fornecendo uma representação mais realista da variabilidade do movimento detectado pelo magnetômetro.

3.10 Modelagem linear para o módulo da aceleração e correção de outliers

Neste exercício, foi desenvolvido um modelo linear para prever o módulo da aceleração utilizando uma janela de p valores anteriores. Para testar a robustez do modelo, foram injetados 10% de outliers no vetor de aceleração, a partir da densidade inicial de 2,18%, correspondendo a 307.398 amostras alteradas.

O objetivo foi eliminar os outliers e substituí-los pelos valores previstos pelo modelo linear, de forma a analisar a sua capacidade de reconstruir o sinal original.

Foram testados valores de p entre 1 e 100, avaliando o erro médio de predição (RMSE) para cada caso.

A Figura 7 mostra a variação do RMSE em função de p .

Observa-se uma queda acentuada do erro a partir de $p=5$, com o RMSE continuando a diminuir progressivamente até $p=100$.

O valor $p=97$ apresentou o menor erro de predição, indicando que, para este conjunto de dados, considerar um histórico mais longo dos valores de aceleração proporciona um melhor equilíbrio entre complexidade e desempenho do modelo.

Esta análise inclui:

i) A distribuição do erro em função de p (Fig. 7), evidenciando que o aumento da janela temporal melhora significativamente a precisão do modelo.




Fig 7 - RMSE em função do tamanho da janela p

ii) Exemplos de plots com valores reais e previstos (Fig. 8), mostrando visualmente a eficácia da substituição dos outliers e a consistência do sinal reconstruído.




Fig 8 - Valores reais vs previstos ($p = 97$)

A Figura 8 mostra o comportamento do modelo para o melhor valor de $p=97$, onde as curvas de valores reais e previstos se sobrepõem, confirmando a eficácia da correção aplicada.

Esta abordagem permite não apenas corrigir valores extremos de forma robusta, mas também preservar a continuidade e a coerência do sinal de aceleração, um fator essencial para análises subsequentes de atividade física e detecção de movimentos anômalos.

Também foi analisada a distribuição do erro de predição para $p=97$, Fig 9, observa-se que a maioria dos erros se concentra entre -15 e 0, mostrando que o modelo tende a subestimar levemente os valores reais de aceleração. Essa predominância de erros negativos, com uma cauda mais alongada à esquerda, revela uma distribuição não uniforme e uma tendência sistemática de subestimação. Em contrapartida, os erros positivos são menos frequentes e de menor magnitude, o que mostra que grandes superestimações são raras. Estes resultados reforçam a robustez do modelo linear na correção dos outliers, embora apontem a possibilidade de futuros aprimoramentos, para reduzir a tendência de subestimação e aumentar a precisão das previsões.




Fig 9 - Distribuição do erro de predição ($p = 97$)

3.11 Modelo linear com janela centrada no instante a prever

Neste exercício, o modelo linear desenvolvido em 3.10 foi adaptado para utilizar uma janela de dimensão p centrada no instante a prever. Isto significa que, para prever o valor do módulo da aceleração em um determinado instante, o modelo levou em conta $p/2$ valores anteriores e $p/2$ valores seguintes da própria variável, além das outras variáveis disponíveis (módulos dos sensores aceleração, giroscópio e magnetômetro), incorporando mais contexto ao redor do ponto a prever.

Para testar a robustez, foram novamente injetados 10% de outliers no vetor de aceleração, correspondendo a 307.397 amostras alteradas, mantendo a densidade inicial de 2,18%.

Os resultados obtidos foram:

- $p = 5 \rightarrow \text{RMSE} = 0.0784$
- $p = 9 \rightarrow \text{RMSE} = 0.0803$
- $p = 15 \rightarrow \text{RMSE} = 0.0804$

O melhor p encontrado é 5, com $\text{RMSE} = 0.0784$.

Comparando com os resultados de 3.10, observa-se que a utilização da janela centrada trouxe apenas uma leve melhoria no RMSE. Como o erro em 3.10 era maior e o melhor p era diferente, isso indica que, para este dataset, adicionar valores futuros e informações de outras variáveis não trouxe uma melhoria substancial na capacidade do modelo linear de corrigir os outliers.

A abordagem centrada, no entanto, é conceitualmente mais rica, pois incorpora informação contextual ao redor do ponto a prever, podendo ser vantajosa em sinais mais ruidosos ou altamente correlacionados entre diferentes sensores.

4.1 Análise da Significância Estatística e da Normalidade das Variáveis nas Diferentes Atividades

As análises das médias dos módulos do acelerômetro, giroscópio e magnetômetro mostraram diferenças claras entre atividades e posições do corpo. Em todos os sensores, o teste de Kolmogorov-Smirnov indicou $p=0.0000$ (exceto algumas atividades do magnetômetro com p ligeiramente maior), confirmando que os dados não seguem distribuição normal.

Foram então aplicados testes paramétricos, como ANOVA e correlações de Pearson, para avaliar diferenças e associações lineares entre grupos. Esses testes indicaram diferenças significativas entre algumas atividades e posições, sugerindo padrões consistentes quando as suposições de normalidade eram atendidas.

Para complementar, testes não paramétricos, como Kruskal-Wallis e correlações de Spearman, foram realizados para verificar diferenças e relações sem depender da normalidade dos dados. Estes testes reforçaram as distinções observadas, mostrando que mesmo com dados não normalmente distribuídos, era possível identificar padrões discriminativos entre atividades e posições.

Para o acelerômetro, as pernas (especialmente a left lower leg) apresentaram as maiores variações, refletindo movimentos mais intensos ou deslocamentos maiores. Tronco e punhos apresentaram variações menores, mas ainda discriminantes entre atividades.

No giroscópio, as diferenças foram mais acentuadas, com picos de média muito maiores em atividades envolvendo rotações rápidas ou movimentos amplos. Novamente, as pernas mostraram os maiores módulos, seguidas pelos punhos e tronco, indicando padrões de rotação distintos de acordo com a atividade.

No magnetômetro, as variações foram menores, mas ainda perceptíveis, mostrando que os magnetômetros captam pequenas diferenças no campo magnético e orientação corporal. Algumas atividades apresentaram médias mais altas, possivelmente relacionadas a movimentos mais amplos ou mudanças de direção.

4.4 Importância das Variáveis e Redução Dimensional do Espaço de Features

Nesta etapa, a análise de importância das variáveis e a redução dimensional foram realizadas com base nas features extraídas por janelas temporais de 2 s, com 50% de sobreposição e frequência de amostragem de 51,2 Hz, para cada atividade individualmente.

O objetivo foi identificar o número mínimo de componentes principais necessários para explicar 75% da variabilidade de cada conjunto de features, reduzindo o espaço dimensional sem perda significativa de informação.

Antes da aplicação do PCA (Principal Component Analysis), todas as features foram normalizadas pelo método z-score. Esta normalização garante que todas as variáveis tenham média zero e desvio padrão unitário, evitando que features com diferentes escalas exerçam influência indevida no cálculo das componentes principais.

Após a normalização, o PCA foi aplicado aos dados adquiridos pela extração das features de cada atividade separadamente, sendo que cada uma foi decomposta em múltiplas janelas temporais, e para cada janela foi calculado um vetor de features independente.

Assim, foi obtida uma matriz de componentes principais por janela, permitindo observar a variabilidade entre as atividade e a contribuição das diferentes features em cada período do sinal.

O PCA transforma o conjunto original de features em novas variáveis ortogonais denominadas componentes principais, que representam combinações lineares das features originais e são ordenadas segundo a quantidade de variância explicada.

Após a aplicação do PCA, observou-se que o processo foi realizado individualmente para cada atividade, considerando as features extraídas por janelas de 2 segundos (com 50% de sobreposição).

Desta forma, para cada atividade foi gerado um conjunto específico de componentes principais e um gráfico de variância explicada, armazenados de forma organizada nos diretórios `data/features/<vetor>/<sensor>/<atividade>/pca_results/`

Devido ao grande número de atividades e consequente quantidade de janelas, foram obtidos diversos gráficos e resultados de PCA, um para cada combinação de vetor e atividade.

O número de componentes principais necessário para atingir o limiar de 75% da variância explicada variou entre 4 a 8 componentes para o vetor aceleração e 6 a 10 componentes para o vetor giroscópio.

Estes intervalos indicam que, independentemente da atividade, a maior parte da variabilidade dos dados pode ser representada de forma eficiente com um número reduzido





de dimensões, o que reforça a presença de correlações significativas entre as features originais.

Em outras palavras, muitas das variáveis calculadas a partir dos sinais dos sensores apresentam redundância estatística, podendo ser substituídas por combinações lineares (as componentes principais) sem perda substancial de informação.

Atividades com maior complexidade motora (como corrida, saltos ou movimentos de membros superiores) tendem a exigir um número ligeiramente maior de componentes para atingir o limiar de 75%, refletindo uma distribuição mais dispersa da variância e maior diversidade nos padrões de movimento.

Por outro lado, atividades mais estáveis e repetitivas (como estar parado ou andar a ritmo constante) são bem representadas com menos componentes, indicando uma estrutura de variação mais concentrada e previsível.

Dentre os diversos resultados obtidos, selecionamos alguns exemplos de aplicação do PCA para ilustrar a variabilidade explicada pelas componentes principais, e os gráficos correspondentes são apresentados a seguir.











Fig 10 - Exemplos PCA aplicados nos vetores Aceleração e Giroscópio (atividades 1-5)

4.4.1. Obtenção das Features Relativas à Compressão

Para reduzir a dimensionalidade, aplica-se o PCA aos vetores de features normalizados por z-score, extraídos de cada janela de 2 segundos com 50% de sobreposição. O PCA transforma as features originais em componentes principais, que são combinações lineares das variáveis iniciais.

Selecionando apenas as primeiras componentes que explicam 75% da variabilidade, obtém-se um vetor de dimensão reduzida, preservando a maior parte da informação relevante. Por exemplo, ao escolher uma janela específica de uma atividade de caminhada, o vetor original de dezenas de features pode ser representado por apenas 4 a 8 componentes principais, mantendo os padrões mais importantes do movimento e descartando redundâncias e ruídos.

Desta forma, cada janela da série temporal é sintetizada em um vetor compacto, permitindo que análises subsequentes, como classificação de atividades, sejam mais eficientes sem perda significativa de informação.

4.4.2. Vantagens e Limitações da Abordagem

Entre as vantagens para esta abordagem, destaca-se a capacidade de simplificar o conjunto de dados e reduzir o ruído, mantendo apenas as componentes principais que concentram a maior parte da variabilidade. Dessa forma, é possível focar nas informações mais relevantes, tornando a análise mais eficiente e rápida, além de potencialmente melhorar o desempenho e a precisão de modelos subsequentes.

Esta abordagem também pode revelar estruturas e relações ocultas nos dados, como padrões sazonais, ciclos ou anomalias, oferecendo uma visão mais clara da dinâmica e do comportamento temporal das variáveis analisadas.

Por outro lado, existem desvantagens significativas. A transformação dos dados em componentes principais implica uma alteração do significado original das variáveis, o que pode dificultar a interpretação e explicação dos resultados no contexto físico ou real. Além disso, este método pressupõe relações lineares e estacionariedade nas séries temporais — isto é, assume que as propriedades estatísticas não mudam ao longo do tempo. Essa suposição nem sempre é válida, pois muitos sinais temporais apresentam comportamentos não lineares e não estacionários, o que pode levar a uma perda de informação importante e impedir que o método capture adequadamente a verdadeira estrutura dos dados.

4.6 Identificação das melhores features segundo Fisher Score e ReliefF

Para organizar as features mais relevantes, aplicamos os métodos de seleção Fisher Score e ReliefF separadamente para cada sensor em cada um dos vetores aceleração e giroscópio. Cada método gera um ranking de pontuação indicando a importância relativa de cada variável na discriminação das atividades. Para facilitar a análise, selecionamos como exemplo os resultados do sensor localizado no tronco (Chest), considerando os dez melhores atributos de cada método. Esta abordagem permite identificar claramente quais aspectos do sinal, seja variabilidade, amplitude, energia ou complexidade espectral, são mais determinantes para diferenciar padrões de movimento. Além disso cabe acrescentar que os demais resultados obtidos encontram-se nos diretórios:

- [data/features/<vetor>/<sensor>/fisher_score.csv](#)
- [data/features/<vetor>/<sensor>/reliefF_score.csv](#)

Fisher Score – Acelerômetro (Chest)

	Feature	Score
1	Range_X	3,889755
2	Range_Y	3,326620
3	IQR_X	3,304601
4	STD_Y	3,156508
5	Max_Y	2,853067
6	AvgDerivative_Y	2,221883
7	AvgDerivative_X	2,200148
8	MaxAccel_X	2,143500
9	MedianAbsDev_Y	2,030532
10	RMS_X	1,583167

Tab 1 - Tabela top 10 do Fisher Score para o Acelerômetro (Chest)

As features mais relevantes do acelerômetro indicam que a variabilidade e a amplitude dos movimentos são fatores determinantes para a discriminação das atividades, com predominância do eixo X, seguido pelo eixo Y. Métricas de dispersão, como *Range* e *IQR*, destacam a ampla variação dos sinais, enquanto medidas estatísticas como *Desvio Padrão (STD)* e *Valor Máximo (Max)* refletem a intensidade e picos de aceleração. As derivadas médias (*AvgDerivative*) descrevem a velocidade de mudança nos movimentos, e o RMS representa a energia total do sinal. Em conjunto, essas variáveis sintetizam de forma abrangente o comportamento dinâmico do tronco, permitindo uma discriminação robusta e eficiente das diferentes atividades físicas.

Fisher Score – Giroscópio (Chest)

	Feature	Score
1	MeanFFT_Z	3,016896
2	Range_Z	3,004172
3	Range_Y	2,850948
4	AvgDerivative_Z	2,812286
5	Std_Z	2,742102
6	AvgDerivative_Y	2,544149
7	SMA	2,319740
8	MeanFFT_Y	2,303430
9	Std_Y	2,221669
10	RMS_Z	2,012887

Tab 2 - Tabela top 10 do Fisher Score para o Giroscópio (Chest)

As features mais relevantes do giroscópio no tronco evidenciam a amplitude, variação e complexidade das rotações, com destaque para o eixo Z, que apresentou os maiores valores de Fisher Score. Métricas como *MeanFFT_Z* e *MeanFFT_Y* capturam componentes de frequência associadas à regularidade e ritmo das rotações, enquanto *Range* e *STD* refletem a amplitude e dispersão angular dos movimentos. As derivadas

médias (AvgDerivative) indicam a velocidade de variação dos sinais, e medidas globais como *SMA* e *RMS* expressam a intensidade total e a energia rotacional do tronco. Essas características, combinadas, permitem uma caracterização detalhada da cinemática rotacional, tornando-se altamente eficazes na diferenciação de padrões de atividade.

ReliefF – Acelerômetro (Chest)

	Feature	Score
1	FFT_Energy_Z	806,906798
2	FFT_Energy_Y	567,236709
3	ENERGY	463,464685
4	FFT_Max_X	41,846222
5	FFT_Max_Z	36,552112
6	FFT_Max_Y	25,671376
7	AAE	21,524187
8	MeanCross_X	7,144469
9	DF	6,499895
10	MeanCross_Y	6,461468

Tab 3 - Tabela top 10 do ReliefF para o Acelerômetro (Chest)

As features mais relevantes segundo o algoritmo ReliefF indicam que a energia e o conteúdo espectral dos sinais do acelerômetro são os principais discriminantes entre diferentes atividades. As métricas FFT_Energy (especialmente nos eixos Z e Y) e ENERGY global dominam amplamente o ranking, revelando que a intensidade e a potência dos movimentos, sobretudo nas componentes verticais e laterais, são altamente informativas.

As variáveis FFT_Max complementam essa análise ao evidenciar os picos de frequência associados aos movimentos mais energéticos, enquanto medidas como AAE (Average Absolute Error) e DF (provavelmente Dominant Frequency ou Derivative Feature, conforme sua definição) capturam flutuações locais e características temporais relevantes.

Por fim, os MeanCross quantificam o número de cruzamentos em torno da média, refletindo a variabilidade e irregularidade dos sinais.

Em conjunto, essas features mostram que o ReliefF favorece informações espectrais e energéticas, destacando tanto a intensidade global quanto a complexidade dinâmica dos movimentos do tronco, fundamentais para a diferenciação precisa entre padrões de atividade física.

ReliefF – Giroscópio (Chest)

	Feature	Score
1	FFT_Energy_Y	8.233.413,551
2	ENERGY	6.017.007,998
3	FFT_Energy_Z	5.227.144,298
4	AAE	224.316,002
5	MaxAccel_Y	376,559825
6	MaxAccel_X	73,953654
7	EVA1	60.421,529
8	FFT_Max_Y	20.888,053
9	FFT_Max_X	7.263,575
10	FFT_Max_Z	6.730,976

Tab 4 - Tabela top 10 do ReliefF para o Giroscópio (Chest)

As features mais relevantes segundo o algoritmo ReliefF indicam que a energia e o conteúdo espectral dos sinais do giroscópio são os principais discriminantes entre diferentes atividades. Métricas como FFT_Energy_Y, FFT_Energy_Z e ENERGY global dominam o ranking, revelando que tanto a intensidade quanto a distribuição de energia nos eixos vertical e lateral são altamente informativas para capturar movimentos do tronco.

As variáveis FFT_Max_Y, FFT_Max_X e FFT_Max_Z complementam essa análise ao evidenciar os picos de frequência associados aos movimentos mais energéticos, sugerindo a presença de movimentos rítmicos ou repetitivos, típicos de caminhada, corrida ou mudanças de postura.

Medidas como MaxAccel_Y e MaxAccel_X refletem as amplitudes máximas do movimento, importantes para identificar movimentos bruscos ou transições rápidas, enquanto AAE e EVA1 capturam flutuações locais e variações cumulativas dos sinais, evidenciando a dinâmica fina dos movimentos do tronco.

Em conjunto, essas features mostram que o ReliefF favorece informações espectrais, energéticas e de magnitude de movimento, destacando tanto a intensidade global quanto a complexidade dinâmica dos movimentos do tronco, fundamentais para a diferenciação precisa entre padrões de atividade física.

4.6.1 Extração e Exemplificação das Features Seleccionadas para Compressão de Dados

As features mais relevantes foram extraídas aplicando os algoritmos Fisher Score e ReliefF sobre os dados de cada sensor e parte do corpo. Para isso, cada conjunto de sinais correspondentes a uma atividade é organizado, e cada feature calculada é avaliada quanto à sua capacidade de discriminar entre diferentes atividades.

No Fisher Score, a relevância de cada feature é estimada considerando a diferença entre a média das classes em relação à variabilidade dentro de cada classe, ou seja, quanto maior a separação entre atividades em comparação com a dispersão interna, mais importante a feature é. Já no ReliefF, cada feature é avaliada pela sua capacidade de diferenciar instâncias próximas de classes diferentes, penalizando características que variam pouco entre atividades e valorizando aquelas que destacam diferenças entre movimentos distintos.

Como exemplo, para um determinado instante de uma atividade, pode-se calcular a energia, amplitude ou variação do sinal do sensor naquela posição. Essas medidas, obtidas separadamente, fornecem vetores de features representativos do movimento naquele momento. Ao aplicar os algoritmos de seleção, essas características recebem uma pontuação de relevância, permitindo gerar um ranking de features que mais contribuem para a detecção e classificação de atividades físicas.

4.6.2 Vantagens e limitações desta abordagem

O Fisher Score é rápido, eficiente e de fácil interpretação, fornecendo uma pontuação clara para cada feature e sendo útil como pré-processamento em dados de alta dimensionalidade. No entanto, ele avalia cada característica de forma independente, ignorando possíveis interações entre features, e algumas versões assumem normalidade e variâncias iguais entre classes, o que pode não se aplicar a todos os conjuntos de dados.

O ReliefF, por sua vez, é robusto a dados ruidosos, problemas multiclasse e dados incompletos, considerando também possíveis interações entre características. Ele avalia a relevância das features comparando instâncias semelhantes e diferentes, destacando aquelas que melhor discriminam as classes. Entre suas limitações, destaca-se que o algoritmo pode não diferenciar adequadamente features redundantes, ou seja, variáveis muito correlacionadas podem receber relevância semelhante sem adicionar informação extra. Além disso, quando há poucas amostras de treinamento, a estimativa da importância das features pode ser menos precisa, pois o cálculo depende da comparação com vizinhos próximos dentro do conjunto de dados.

Em conjunto, estas técnicas permitem selecionar features relevantes de forma eficiente, mas devem ser usadas considerando as suas restrições e características do conjunto de dados.